Claude Certified Developer – Foundations (CCDV-F)

Simulado · D1 / S3

53 questões · Tempo: 120 minutos · Português

Instruções

- Cada questão informa quantas respostas selecionar. Nas de múltipla resposta, acerta-se somente com o conjunto exato de alternativas corretas (sem nota parcial).
- Meça o tempo: 120 minutos para 53 questões (cerca de 2 min 15 s por questão). Marque as dúvidas e volte a elas.
- Use somente a folha de respostas na última página. Não consulte materiais durante o simulado.
- Este é um material de estudo não oficial, com questões originais. Não reproduz itens reais do exame (confidenciais por NDA).

Domínio: D1 Agents & Workflows (8) · D2 Applications & Integration (17) · D3 Claude Code (2) · D4 Eval, Testing & Debugging (1) · D5 Model Selection & Optimization (9) · D6 Prompt & Context Engineering (6) · D7 Security & Safety (4) · D8 Tools & MCPs (6)

Questão 1 · **Selecione 3 respostas.**

O CI de uma equipe chama a API real do Claude em todo pull request: o pipeline é lento, caro e instável. A equipe quer testar o código de integração de forma confiável. Selecione 3 práticas adequadas.

A. Usar, no pipeline do PR, dublês do cliente da API com respostas realistas gravadas, incluindo tool_use, erros 429/529 e eventos de erro no stream

B. Medir a qualidade das respostas do modelo em uma suíte de evals separada, pois dublês só verificam o código de integração e não o comportamento do modelo

C. Rodar periodicamente uma pequena suíte de contrato contra a API real para checar se os dublês ainda refletem o formato real, abrindo tarefa de ajuste se divergirem

D. Escrever dublês apenas com o caminho feliz em JSON feito à mão, já que nunca será necessário comparar com respostas reais

E. Manter as chamadas reais em todo PR e repetir o job até ficar verde, pois a instabilidade é só ruído

Questão 2 · **Selecione 2 respostas.**

Sua tool update_ticket tem o parâmetro status como string livre. Em produção Claude envia "Done", "finished" e "fechado", mas a API só aceita open, in_progress e closed. Quais mudanças na definição da tool atacam a causa? Selecione 2.

A. Declarar status com "enum": ["open", "in_progress", "closed"] no input_schema e explicar cada valor na description do parâmetro.

B. Adicionar input_examples com chamadas válidas, mostrando os valores de status aceitos.

C. Usar tool_choice forçado do tipo tool, para que Claude sempre chame update_ticket.

D. Reduzir a description da tool a uma frase curta, para não confundir o modelo.

E. Mapear em silêncio, no handler, qualquer valor desconhecido para "open", para nunca falhar.

Questão 3 · **Selecione 1 resposta.**

Um dev ativa o thinking com display "omitted" para a resposta não trazer texto de raciocínio, achando que assim deixará de pagar pelo thinking. O que de fato acontece na cobrança?

A. O raciocínio é cobrado como tokens de input, a uma taxa menor que a de output.

B. Só o texto visível é cobrado; como o campo thinking vem vazio, os tokens de raciocínio ficam sem custo.

C. Os tokens de thinking realmente gerados são cobrados como output, independentemente do display; o detalhamento aparece em usage.output_tokens_details.thinking_tokens.

D. É cobrado apenas um resumo do raciocínio, proporcional ao tamanho do texto resumido.

Questão 4 · **Selecione 1 resposta.**

Um agente do Agent SDK tem três ferramentas customizadas, todas apenas de consulta (lookup_customer, lookup_order, lookup_inventory). Quando Claude pede as três no mesmo turno, elas rodam uma após a outra e a latência triplica. Qual a melhor correção?

A. Adicionar as três ferramentas a allowed_tools, para que o SDK as trate como seguras para execução concorrente.

B. Marcar as ferramentas como somente leitura via readOnlyHint nas annotations, pois ferramentas customizadas são sequenciais por padrão.

C. Reduzir effort para low, para que Claude peça menos chamadas por turno.

D. Aumentar max_turns, para que Claude possa distribuir as chamadas por vários turnos.

Questão 5 · **Selecione 2 respostas.**

No meio de uma conversa longa no Claude Code, o desenvolvedor quer testar uma abordagem alternativa de refatoração partindo do histórico atual, sem alterar a conversa original, que deve continuar disponível. Selecione 2 formas adequadas.

A. /branch, com um nome opcional para a nova conversa.

B. claude --continue --fork-session, que copia o histórico para um novo ID de sessão.

C. /compact, que resume o histórico para liberar espaço.

D. /clear, que começa com o contexto vazio e preserva o histórico anterior.

E. claude --resume <nome>, que reabre a sessão e segue a partir dela.

Questão 6 · **Selecione 1 resposta.**

Um serviço captura Exception genérica ao chamar a API e decide o que fazer com checagens como `"overloaded" in str(e)`. Após uma mudança de redação nas mensagens de erro, o tratamento parou de funcionar. Qual é a melhor abordagem?

A. Capturar as classes de exceção tipadas do SDK, das mais específicas para as mais gerais, e decidir por tipo/status do erro.

B. Definir max_retries=0 no cliente, para que o SDK devolva o erro como JSON bruto em vez de lançar exceção.

C. Extrair o código HTTP com regex a partir do texto da mensagem de erro.

D. Adicionar mais substrings à checagem para cobrir as novas redações.

Questão 7 · **Selecione 2 respostas.**

Você extrai dados de contratos com a API usando saída estruturada. Muitos contratos não informam a data de término nem o foro, e o modelo às vezes inventa valores plausíveis para esses campos. Quais mudanças de schema reduzem o problema? Selecione 2.

A. Colocar todos os campos em required, para que o modelo sempre devolva um valor para cada um.

B. Adicionar minLength: 1 a todas as strings para impedir valores vazios.

C. Modelar o campo tipo_rescisao como enum que inclua um valor explícito como "nao_informado", em vez de string livre.

D. Deixar data_termino e foro fora de required, tornando-os opcionais, para que a ausência da informação possa ser representada.

E. Confiar que a saída estruturada garante que os valores extraídos sejam verdadeiros em relação ao documento.

Questão 8 · **Selecione 1 resposta.**

Você criou a skill /deploy, que executa o procedimento de deploy em produção. Quer que ela rode apenas quando você digitar /deploy, nunca por iniciativa de Claude por achar que a conversa pede um deploy. O que fazer?

A. Definir disable-model-invocation: true no frontmatter da skill.

B. Listar apenas ferramentas seguras em allowed-tools na skill.

C. Definir context: fork no frontmatter, para rodar em um subagent isolado.

D. Mover o procedimento para o CLAUDE.md, que só é lido quando você pede.

Questão 9 · **Selecione 2 respostas.**

Um agente do Agent SDK foi configurado com max_turns=5 para corrigir testes. Em produção, algumas execuções terminam sem nenhum texto final. Selecione 2 afirmações corretas sobre esse comportamento e seu tratamento.

A. O SDK dobra automaticamente max_turns e continua o loop quando o limite é atingido.

B. O ResultMessage ainda traz session_id, permitindo retomar a sessão com um limite maior para continuar o trabalho.

C. A execução termina com um ResultMessage de subtype error_max_turns, sem o campo result; o código deve checar o subtype antes de ler result.

D. Aumentar max_budget_usd também eleva o limite de turnos, então basta subir o orçamento para o loop rodar por mais tempo.

E. max_turns conta apenas turnos com chamadas de ferramenta; a resposta final só de texto nunca consome turno.

Questão 10 · **Selecione 1 resposta.**

Um banco vai lançar um chatbot de suporte baseado em Claude. A área de compliance exige que "toda resposta dada a um cliente seja auditável". Qual decisão de projeto atende melhor a esse requisito?

A. Persistir, por resposta, o id da conversa, a versão do prompt, o modelo usado, o request-id devolvido pela API e as mensagens trocadas, com retenção definida

B. Registrar apenas o texto final exibido ao cliente, para reduzir o volume armazenado e o risco de reter dados sensíveis

C. Ativar streaming, pois os eventos SSE recebidos pelo navegador do cliente já constituem um registro auditável da interação

D. Confiar nos logs mantidos pela Anthropic e solicitá-los ao provedor sempre que ocorrer uma auditoria interna ou externa

Questão 11 · **Selecione 2 respostas.**

A equipe quer um procedimento /release que só rode quando alguém digitar o comando (nunca por decisão do Claude) e cujo material de referência longo (checklist e templates) não ocupe contexto em toda sessão. Selecione 2 práticas adequadas.

A. Colar o procedimento completo e os templates no CLAUDE.md do projeto.

B. Definir user-invocable: false, para que a skill só seja usada de forma deliberada.

C. Usar allowed-tools para controlar quando o Claude pode acionar a skill.

D. Criar .claude/skills/release/SKILL.md com disable-model-invocation: true.

E. Manter checklist e templates em arquivos separados na pasta da skill, referenciados a partir do SKILL.md.

Questão 12 · **Selecione 3 respostas.**

Um job noturno envia 50 mil requisições ao Message Batches API, todas com o mesmo documento de 30k tokens como prefixo e perguntas diferentes. Não há urgência de resposta. Selecione 3 práticas corretas para minimizar o custo.

A. Dentro do lote, fazer uma requisição com max_tokens 0 para pré-aquecer o cache antes das demais.

B. Incluir blocos cache_control idênticos em todas as requisições do lote para aumentar a chance de cache hits.

C. Contar com hits garantidos, já que o lote processa as requisições em ordem sequencial.

D. Considerar o TTL de 1 hora, pois lotes podem levar mais de 5 minutos para processar.

E. Usar o Batches API, que dá 50% de desconto para trabalho assíncrono sem urgência.

Questão 13 · **Selecione 2 respostas.**

Seu time habilitou 12 plugins no Claude Code e nota que as sessões começam com menos espaço de contexto, mesmo em tarefas que usam poucos deles. Quais afirmações sobre o custo dos plugins são verdadeiras? Selecione 2.

A. Dá para parar o custo sem desinstalar, desabilitando o plugin com /plugin ou com claude plugin disable.

B. O nome e a descrição de cada skill que Claude pode invocar sozinho ficam no contexto a cada turno, mesmo em sessões em que nada do plugin é usado.

C. Desinstalar é a única forma de remover o custo de contexto de um plugin.

D. Um plugin só afeta a sessão quando uma de suas skills é invocada; hooks e servidores MCP ficam inativos até lá.

E. O texto completo de todas as skills dos plugins habilitados é carregado no início de cada sessão.

Questão 14 · **Selecione 3 respostas.**

Um dev está estimando quanto da janela de contexto uma requisição de agente consome. A requisição tem system prompt, 12 definições de tools, histórico com blocos tool_result e o texto que Claude vai gerar no turno. Quais afirmações sobre o que conta para a janela de contexto são corretas? Selecione 3.

A. O conteúdo dos blocos tool_result no histórico conta como qualquer outra mensagem.

B. O texto que Claude gera no turno, incluindo o thinking, conta para a janela.

C. As definições de tools contam para a janela, assim como o system prompt.

D. Tokens lidos de um prefixo em cache (prompt caching) deixam de ocupar a janela; o cache altera apenas o preço.

E. Só as mensagens user/assistant contam; system prompt e definições de tools ficam fora da conta.

Questão 15 · **Selecione 2 respostas.**

Um time quer reduzir o risco de vazar chaves de API da Claude antes que aconteça qualquer incidente. Quais duas práticas de prevenção são recomendadas? Selecione 2.

A. Manter a mesma chave sem rotação até suspeitar de vazamento.

B. Verificar regularmente os repositórios com uma ferramenta como Gitleaks.

C. Codificar a chave em base64 no bundle do front-end para que não fique legível.

D. Compartilhar uma única chave do time por chat para acelerar o onboarding.

E. Carregar a chave por variável de ambiente e listar .env no .gitignore.

Questão 16 · **Selecione 1 resposta.**

Um prompt cola três contratos como texto corrido separados por linhas '---', seguidos das instruções. Claude às vezes atribui uma cláusula ao contrato errado e confunde trechos dos contratos com as instruções. Qual a melhor correção?

A. Mover os três contratos para o system prompt, para que tenham mais autoridade que as instruções.

B. Envolver cada contrato em <document index="n"> com <source> e <document_content>, dentro de <documents>.

C. Repetir as instruções depois de cada contrato para que Claude não as confunda com o texto.

D. Trocar os separadores '---' por banners em letras maiúsculas como '=== CONTRATO 2 ==='.

Questão 17 · **Selecione 1 resposta.**

Um agente de suporte lê tickets de clientes e tem a tool query_db com credencial de administrador do banco e a tool send_email sem restrição de destinatário. A equipe teme que um ticket malicioso faça o agente exfiltrar dados. Qual a melhor abordagem?

A. Pedir educadamente nos tickets de teste que o agente ignore instruções contidas no texto do cliente.

B. Adicionar ao system prompt a frase 'nunca envie dados a terceiros' e manter as permissões atuais.

C. Credencial somente leitura nas tabelas necessárias, tools estreitas e nenhum segredo desnecessário.

D. Registrar logs de auditoria de todas as chamadas de tool e revisá-los semanalmente, mantendo as permissões.

Questão 18 · **Selecione 2 respostas.**

Sua equipe tem a função lookup_customer, que consulta o CRM. Hoje só um serviço interno, que chama a Messages API, a usa. Em breve ela também será usada no Claude Code, no Claude Desktop e em outro app. Quais motivos justificam empacotá-la como servidor MCP? Selecione 2.

A. Vários hosts (Claude Code, Claude Desktop, outros apps) podem conectar ao mesmo servidor em vez de cada um reimplementar a tool.

B. Tools definidas no código da aplicação não conseguem acessar APIs internas; só servidores MCP conseguem.

C. A Messages API só aceita tools que venham de servidores MCP.

D. A conexão e a autenticação com o CRM ficam em um só lugar, tratadas pelo servidor, e não duplicadas em cada cliente.

E. Uma tool exposta por MCP é chamada pelo modelo com mais precisão do que uma tool definida no código da aplicação.

Questão 19 · **Selecione 2 respostas.**

Um assistente responde perguntas sobre um relatório anual e, às vezes, afirma com tom confiante números que não estão no relatório. Quais duas medidas ajudam a reduzir e detectar isso? Selecione 2.

A. Rodar o mesmo prompt várias vezes e revisar as respostas que divergirem, pois podem indicar alucinação.

B. Instruir Claude a completar com conhecimento geral quando o relatório não trouxer o dado.

C. Dispensar a validação humana depois de restringir as respostas ao relatório.

D. Pedir que Claude informe uma confiança de 0 a 100 e aceitar automaticamente respostas acima de 90.

E. Dar permissão explícita para responder que não há informação suficiente quando o relatório não trouxer o dado.

Questão 20 · **Selecione 2 respostas.**

O requisito de um chatbot de suporte diz apenas: "deve ser rápido e estar sempre disponível". Antes de projetar, a equipe precisa transformá-lo em requisitos verificáveis. Selecione 2 abordagens adequadas.

A. Fixar 100% de disponibilidade como meta, sem nenhuma resposta de erro tolerada em qualquer período

B. Definir p95 do tempo até o primeiro token abaixo de um valor acordado, sob uma carga de sessões simultâneas especificada, medido em produção

C. Exigir latência média abaixo do alvo, já que a média resume bem a experiência de todos os usuários

D. Definir um SLO de disponibilidade (por exemplo, % de requisições atendidas com sucesso no mês) e o comportamento degradado esperado quando a API retornar 429 ou 529

E. Escolher sempre o maior modelo disponível, pois isso garante respostas rápidas e disponibilidade

Questão 21 · **Selecione 1 resposta.**

O repositório tem .claude/settings.json versionado com permissions.allow ["Bash(npm run lint)"] e permissions.deny ["Read(./.env)"]. Uma pessoa nova clona o repo e abre o Claude Code, ainda sem ter confiado (trust) na pasta. O que acontece?

A. Nenhuma das duas vale até a confiança, então o .env pode ser lido nesse intervalo.

B. A regra allow vale de imediato, enquanto a deny só vale após confiar na pasta, por exigir confirmação.

C. A regra deny vale de imediato; a regra allow só passa a valer depois de confiar na pasta, então o lint ainda pede confirmação.

D. As duas regras valem imediatamente, pois o arquivo está versionado no repositório.

Questão 22 · **Selecione 1 resposta.**

Sua empresa quer um servidor MCP somente-leitura sobre o ERP, usado por centenas de devs no Claude Code (e por outros apps), com identificação do usuário em cada acesso. Qual desenho é o mais adequado?

A. Servidor remoto com transporte SSE, por ser o mais recomendado para serviços remotos.

B. Um único processo stdio em um host central, ao qual todos os devs se conectam ao mesmo tempo.

C. Servidor remoto com transporte Streamable HTTP, autenticação HTTP padrão (OAuth recomendado pelo MCP para obter tokens) e clientes conectando por URL.

D. Servidor stdio que cada dev executa localmente, com a credencial do ERP em variável de ambiente.

Questão 23 · **Selecione 1 resposta.**

Uma ferramenta interna chama o Claude uma vez a cada ~30 minutos com o mesmo prefixo grande e cache_control com o TTL padrão. A cobrança subiu após habilitar caching e a resposta mostra cache_creation_input_tokens alto e cache_read_input_tokens sempre 0. Qual é a melhor interpretação e ação?

A. O prefixo é pequeno demais, por isso nada é lido; aumentar max_tokens resolve.

B. O TTL padrão (5 minutos) expira antes da próxima chamada (~30 minutos): toda requisição paga a escrita no cache e nunca lê; a ação é remover o caching ou avaliar o TTL de 1 hora, que cobre esse intervalo entre chamadas.

C. Os campos de usage estão errados em modelos recentes; o cache está funcionando e a cobrança vai estabilizar.

D. É preciso adicionar mais breakpoints (até 4) para que o cache comece a ser lido.

Questão 24 · **Selecione 1 resposta.**

Uma equipe guarda o system prompt de um extrator em um repositório e o edita no lugar sob o rótulo "v2". Uma reformulação "pequena" mudou o formato da saída, quebrou o parser downstream e foi para 100% do tráfego de uma vez, mesmo com os evals offline passando. A equipe decide adotar versionamento semântico (SemVer) para os prompts. Qual abordagem de versionamento e rollout é a melhor?

A. Escolher o número da versão pelo tamanho do diff: poucas linhas alteradas significam PATCH, mesmo que o formato da saída mude

B. Liberar direto para 100% quando os evals offline passarem, pois eles substituem a observação em produção

C. Manter o rótulo "v2" e sobrescrevê-lo a cada ajuste, pois o histórico do Git já permite voltar a qualquer versão anterior

D. Declarar o formato de saída como a API pública do prompt, tratar versões publicadas como imutáveis (qualquer mudança vira nova versão; formato quebrado = MAJOR), passar pelos evals e liberar em canário com métricas e rollback

Questão 25 · **Selecione 2 respostas.**

Um subagente de revisão foi definido em .claude/agents/reviewer.md, com description "Revisor somente leitura; nunca altera arquivos" e sem campo tools. Mesmo assim ele usou Write e Edit. A equipe exige que essas duas ferramentas fiquem indisponíveis para ele. Selecione 2 ajustes eficazes.

A. Adicionar disallowedTools: Write, Edit ao frontmatter do subagente.

B. Definir isolation: worktree, para que as edições nunca cheguem ao checkout principal.

C. Reforçar no campo description que o subagente jamais deve usar Write ou Edit.

D. Adicionar tools: Read, Grep, Glob ao frontmatter do subagente.

E. Definir model: haiku, pois um modelo menor tende a editar menos.

Questão 26 · **Selecione 1 resposta.**

Um app de FAQ em um modelo tier Sonnet usa adaptive thinking. Monitorando, você vê blocos de thinking em muitas perguntas triviais, aumentando latência e custo de output. Adicionar ao system prompt "não pense, responda direto" não reduziu de forma confiável. Qual é a melhor abordagem?

A. Definir um budget_tokens pequeno em thinking, para limitar o raciocínio a poucos tokens.

B. Reduzir o nível de effort (output_config.effort), medir o impacto na qualidade e só então complementar com orientação no prompt, se necessário.

C. Reforçar o system prompt com mais ênfase ("NUNCA pense") e assumir que o modelo obedecerá sempre.

D. Aumentar max_tokens para que o thinking termine mais rápido e libere a resposta.

Questão 27 · **Selecione 1 resposta.**

Um time cria um hook PreToolUse que detecta quando Claude Code tenta ler um arquivo .env, imprime uma mensagem no stderr e termina com exit 1. Mesmo assim, o arquivo continua sendo lido. Qual a melhor correção?

A. Manter exit 1, que por ser o código convencional de falha em Unix já bloqueia a ação.

B. Mover a lógica para um hook PostToolUse, que roda depois que a tool executou.

C. Terminar o script com exit 2: em PreToolUse isso bloqueia a tool call e o stderr vira a mensagem do bloqueio.

D. Imprimir a mensagem no stdout e terminar com exit 0, pois a mensagem sozinha cancela a tool call.

Questão 28 · **Selecione 2 respostas.**

A tool get_invoice(invoice_id) roda no seu backend, com strict: true e invoice_id como string no schema. Outra tool devolve, em um tool_result, o texto de um e-mail de terceiros que tenta induzir Claude a pedir a fatura de OUTRO cliente. Quais afirmações são verdadeiras? Selecione 2.

A. strict: true garante que o invoice_id enviado pertença ao cliente autenticado.

B. strict: true garante que as entradas da tool correspondam ao schema declarado.

C. O conteúdo não confiável deve ser colocado no system prompt, que é o lugar mais seguro para ele.

D. O conteúdo de tool_result vindo de fontes externas, como e-mails, deve ser tratado como não confiável, pois pode embutir instruções para redirecionar Claude (injeção indireta de prompt).

E. O e-mail está dentro de um tool_result, então o seu conteúdo é confiável por vir do seu próprio backend.

Questão 29 · **Selecione 1 resposta.**

Trace de um agente: nos turnos 1, 2 e 3 Claude chama search_docs com {"query":"rate limits"} e recebe is_error=true: "Missing required 'repo' parameter". No turno 4 ele pede desculpas e desiste. O schema de search_docs exige repo, mas a descrição é "Search docs." e repo não tem description. Qual a melhor correção?

A. Aumentar max_turns para que Claude acabe acertando o parâmetro em mais tentativas.

B. Aumentar tentativas e backoff no executor da ferramenta, pois a integração está falhando.

C. Trocar para tool_choice forçado em search_docs, pois Claude escolheu a ferramenta errada.

D. Detalhar a descrição da ferramenta e do parâmetro repo (o que é, valores válidos) e habilitar strict: true, tratando o problema como definição insuficiente.

Questão 30 · Selecione 1 resposta.

Seu app usa a Messages API com uma tool client issue_refund, que movimenta dinheiro. Você quer que um humano aprove cada reembolso antes de ele acontecer. Qual abordagem?

A. Transformar issue_refund em server tool, para que a execução e a aprovação fiquem a cargo da Anthropic.

B. No seu código que trata o bloco tool_use, pausar antes de executar, pedir a aprovação e, se negada, devolver um tool_result com is_error true explicando a negativa.

C. Deixar o handler executar o reembolso e, se o humano discordar depois, pedir a Claude que estorne.

D. Escrever na description da tool "sempre peça aprovação ao usuário antes de chamar" e confiar que Claude cumprirá.

Questão 31 · Selecione 1 resposta.

Um app faz streaming de uma resposta em que Claude chama uma ferramenta. O código executa json.loads em cada partial_json recebido nos eventos input_json_delta e lança exceção em quase todo evento. Qual a abordagem correta?

A. Capturar a exceção e usar o último fragmento que foi parseado com sucesso como os argumentos da ferramenta

B. Acumular os fragmentos por índice de bloco, fazer o parse ao receber content_block_stop e só então executar a ferramenta

C. Executar a ferramenta assim que o primeiro campo aparecer no fragmento, com um regex, para reduzir a latência

D. Desativar o streaming apenas durante o tool use, pois não há forma de obter o JSON dos argumentos em requisições com stream

Questão 32 · Selecione 1 resposta.

Uma equipe usa uma única chamada ao Claude para revisar mudanças de código em busca de vulnerabilidades. O problema é a variância: em execuções repetidas, achados reais ora aparecem, ora somem. Que padrão de workflow ataca esse problema?

A. Voting: rodar a mesma revisão várias vezes de forma independente e sinalizar a mudança quando um número suficiente de execuções apontar problema.

B. Routing: classificar cada mudança por linguagem e encaminhá-la a um prompt de revisão especializado.

C. Prompt chaining: encadear a revisão por um segundo prompt que reescreve e refina o texto do relatório.

D. Sectioning: dividir o diff em partes independentes e processar cada parte em paralelo, cada uma com um prompt diferente.

Questão 33 · Selecione 2 respostas.

Uma aplicação usa um modelo com janela de 1M tokens. Cada requisição envia um prefixo de 300k tokens marcado com prompt caching, mais a pergunta do usuário, com adaptive thinking ativo e max_tokens definido. Um colega faz afirmações sobre o uso da janela de contexto. Selecione 2 afirmações corretas.

A. Os tokens de thinking gerados contam para a janela de contexto e fazem parte do limite de max_tokens.

B. A janela limita apenas o input; os tokens de saída são contabilizados em um limite separado.

C. Os 300k tokens do prefixo lidos do cache continuam ocupando a janela de contexto; o caching muda o preço desses tokens, não o espaço que ocupam.

D. Tokens lidos do cache não contam para a janela, pois não são reprocessados como input normal.

E. Se o input sozinho exceder a janela, a API trunca silenciosamente as mensagens mais antigas e responde normalmente.

Questão 34 · **Selecione 2 respostas.**
Antes de enviar prompts grandes, sua API interna chama o endpoint de contagem de tokens para decidir roteamento e checar limites. Selecione 2 afirmações corretas sobre esse endpoint.

A. Retorna uma estimativa; o número real de tokens de input na criação da mensagem pode diferir por uma pequena margem.
B. Retorna o número exato que será faturado, sempre idêntico ao usage da resposta real.
C. O uso é gratuito, sujeito a limites de requisições por minuto próprios, independentes dos da criação de mensagens.
D. Respeita blocos cache_control, então o resultado já reflete o desconto de leitura de cache.
E. Aceita a mesma requisição da Messages API, inclusive com server tools como web search.

Questão 35 · **Selecione 1 resposta.**
Um agente do Agent SDK recebeu no prompt inicial a regra "escreva sempre as notas de release em português". Em sessões longas, após eventos compact_boundary, ele passa a escrever em inglês. Qual a melhor correção?

A. Definir effort como max para que o modelo lembre melhor das instruções iniciais.
B. Mover a regra para um CLAUDE.md carregado via setting_sources, que é reinjetado em cada requisição.
C. Aumentar max_budget_usd para que o contexto original não seja resumido.
D. Retomar a sessão a cada turno com o session_id para restaurar o prompt original.

Questão 36 · **Selecione 1 resposta.**
Em um loop de agente, uma resposta chega com stop_reason "max_tokens" e o último bloco de conteúdo é um tool_use cujo input JSON parece cortado no meio. O que fazer?

A. Tratar a resposta como incompleta e repetir a requisição com um max_tokens maior, em vez de executar a ferramenta.
B. Enviar o tool_use parcial de volta como tool_result e pedir ao modelo que complete o JSON.
C. Executar a ferramenta com o input parcial, assumindo que os campos que chegaram bastam.
D. Ignorar o stop_reason, pois o SDK completa automaticamente chamadas de ferramenta truncadas.

Questão 37 · **Selecione 3 respostas.**
Um serviço Node processa 2.000 documentos disparando todas as chamadas à API com Promise.all e recebe uma enxurrada de erros 429. Selecione 3 correções adequadas.

A. Aumentar a carga de forma gradual em vez de saltar do zero ao pico, evitando também os limites de aceleração
B. Repetir a requisição imediatamente em loop, até uma das tentativas passar
C. Adicionar retries independentes em cada camada (fila, serviço e cliente), para que cada falha tenha mais chances de passar
D. Limitar a concorrência com um pool de workers ou semáforo, dimensionado abaixo dos limites de taxa da organização
E. Aplicar retry com backoff exponencial e jitter, respeitando o header retry-after quando presente e com número máximo de tentativas

Questão 38 · **Selecione 1 resposta.**
Um agente do Agent SDK vai conduzir uma refatoração extensa. A equipe quer que ele leia o código e proponha um plano para aprovação humana antes de modificar qualquer arquivo. Qual permission_mode atende?

A. plan, em que Claude explora e planeja, e edições feitas com suas ferramentas de arquivo vão para o callback canUseTool.
B. dontAsk, que nunca pergunta e por isso nada não revisado chega a ser executado.

C. bypassPermissions, que executa as chamadas sem pedir aprovação e é recomendado para testes locais.

D. acceptEdits, que aprova edições automaticamente para acelerar a iteração.

Questão 39 · **Selecione 1 resposta.**

No Claude Code do seu time há duas instruções: (1) "os testes rodam com pnpm test e os handlers da API ficam em src/api/handlers/"; (2) "respostas curtas, com pouca explicação", que alguns devs querem desligar quando estão aprendendo o código. Onde colocar cada uma?

A. (1) em uma skill com disable-model-invocation; (2) em um hook SessionStart.

B. (1) em CLAUDE.md; (2) em um output style, que pode ser trocado quando se quiser.

C. (1) em um output style; (2) em CLAUDE.md.

D. As duas em CLAUDE.md, pois ele é carregado em toda sessão e cobre qualquer tipo de instrução.

Questão 40 · **Selecione 1 resposta.**

Uma equipe vai migrar de um modelo de geração antiga para um tier de geração mais nova, mantendo os mesmos prompts. O orçamento de custo e a verificação de "cabe na janela" usam contagens de tokens medidas no modelo antigo. Qual é a melhor abordagem?

A. Reaproveitar as contagens, pois o número de tokens de um texto é o mesmo em qualquer modelo Claude.

B. Reavaliar só se o preço por milhão de tokens mudar; caso contrário, o orçamento continua válido.

C. Recontar os prompts com o endpoint de contagem usando o modelo de destino e refazer estimativas de custo e de janela, além de rodar evals.

D. Assumir que modelos mais novos sempre geram menos tokens para o mesmo texto e reduzir o orçamento.

Questão 41 · **Selecione 1 resposta.**

Um serviço usa output_config.format com um JSON schema e grava a saída do Claude direto no banco. Em produção, às vezes o parse falha em respostas cortadas ao meio. Qual a melhor abordagem?

A. Aplicar uma função que "conserta" JSON truncado, fechando chaves e aspas, e gravar o resultado reparado

B. Tratar a saída como sempre válida, já que structured outputs garantem o schema em qualquer resposta

C. Remover o schema e iniciar o turno do assistente com "{" para forçar o formato JSON nos modelos mais recentes

D. Verificar o stop_reason antes de parsear, tratar max_tokens (retry com limite maior) e refusal como casos à parte, e validar na borda antes de gravar

Questão 42 · **Selecione 1 resposta.**

Em uma sessão longa do Claude Code você pede um ajuste de formatação. Claude erra, você corrige, e ele erra a mesma coisa de novo. Qual a melhor ação a seguir?

A. Rodar /clear e começar com um único prompt novo que já incorpora o que você aprendeu nas tentativas.

B. Fazer uma terceira correção, escrevendo a instrução em letras maiúsculas para dar ênfase.

C. Adicionar ao CLAUDE.md a frase em CAPS LOCK com IMPORTANT e continuar na mesma sessão.

D. Continuar corrigindo na mesma conversa, pois mais histórico de tentativas dá mais contexto ao modelo.

Questão 43 · **Selecione 3 respostas.**

Um job com a Message Batches API de 5.000 requisições terminou com 4.700 resultados succeeded, 200 errored e 100 expired. Selecione 3 práticas corretas para consolidar e recuperar o trabalho.

A. Reenviar em um novo batch os itens expired e com erro de servidor, e corrigir antes os itens com invalid_request_error

B. Associar cada resultado à entrada pela posição da linha no arquivo de resultados, já que ele segue a ordem de envio

C. Associar cada resultado à entrada de origem pelo custom_id, pois a ordem dos resultados não é garantida

D. Contar que itens errored e expired não são cobrados, então reprocessá-los não paga duas vezes pelo mesmo trabalho

E. Reenviar o batch inteiro de 5.000 itens para garantir que todos os resultados venham do mesmo processamento

Questão 44 · **Selecione 1 resposta.**

Em um chat com Claude, o dev chama a Messages API a cada turno enviando só a nova mensagem do usuário. O assistente "esquece" tudo o que foi dito antes. Qual a correção mais adequada?

A. Aumentar max_tokens, para que o modelo consiga reter mais contexto entre uma chamada e outra

B. Enviar a cada chamada apenas as falas anteriores do usuário, omitindo as respostas do assistente para economizar tokens

C. Reutilizar o mesmo header request-id em todos os turnos, para que a API associe as chamadas à mesma conversa

D. Guardar a lista de mensagens da conversa e enviá-la completa a cada chamada, anexando a resposta do assistente e a nova fala do usuário

Questão 45 · **Selecione 1 resposta.**

Um serviço de triagem usa output_config.format com um JSON schema cujo campo "categoria" é um enum com os valores "Cobrança", "Suporte técnico" e "Outros". O código compara a categoria recebida por igualdade exata e, de vez em quando, cai no ramo "desconhecido" porque chegou, por exemplo, "Suporte Técnico". Qual a melhor correção?

A. Comparar o valor sem diferenciar maiúsculas de minúsculas (normalizando antes) e evitar valores de enum que difiram apenas na capitalização.

B. Abandonar structured outputs e pedir JSON em texto livre, perdendo a conformidade de estrutura garantida pelo schema.

C. Assumir que o schema garante a grafia exata do enum e tratar a divergência como bug da API a ser reportado.

D. Tratar como erro transitório e repetir a requisição até o valor vir exatamente como no schema.

Questão 46 · **Selecione 1 resposta.**

Um pipeline gera resumos de contratos. O time quer registrar o rascunho, avaliar a revisão do rascunho contra critérios e, entre as etapas, decidir se segue para o refinamento ou desvia para revisão humana. Qual a melhor abordagem?

A. Dividir em chamadas sequenciais (rascunho, revisão, refinamento) e ramificar a partir da saída de cada etapa.

B. Um único prompt que pede rascunho, revisão e versão final, retornando só a versão final para reduzir tokens.

C. Aumentar o effort da chamada única para que a revisão interna fique mais rigorosa e dispensar o log das etapas.

D. Confiar no adaptive thinking para fazer as três etapas internamente, já que o modelo raciocina sobre múltiplos passos sozinho.

Questão 47 · **Selecione 1 resposta.**

Um chat web mostra a resposta do Claude token a token. O usuário envia cada pergunta por uma requisição POST normal, e o servidor só precisa empurrar texto de volta durante a geração. Qual transporte do servidor para o navegador é a melhor escolha?

A. Chamar a API da Anthropic direto do navegador com a chave embutida no JavaScript, eliminando o servidor intermediário

B. Polling a cada 100 ms em um endpoint, buscando os novos tokens acumulados

C. WebSocket, porque streaming de respostas exige um canal bidirecional entre navegador e servidor

D. Server-Sent Events sobre HTTP, pois o fluxo é apenas do servidor para o cliente e o navegador reconecta automaticamente

Questão 48 · **Selecione 1 resposta.**

Seu time quer que todos no repositório iniciem o Claude Code com o mesmo modelo por padrão, e que mudar essa escolha passe por code review e possa ser revertida. Qual abordagem?

A. Cada dev roda /model e salva a escolha, que é gravada no ~/.claude/settings.json de cada um.

B. Escrever no CLAUDE.md do projeto uma linha pedindo que Claude use o modelo desejado.

C. Definir a chave model em .claude/settings.json e versioná-la no repositório.

D. Definir a chave model no .claude/settings.local.json de cada dev.

Questão 49 · **Selecione 1 resposta.**

A saída de Claude é enviada a um gateway de SMS que quebra com markdown. O system prompt diz 'NUNCA use markdown' e ainda aparecem asteriscos de vez em quando. Qual a melhor melhoria?

A. Mover a proibição para o final de cada mensagem do usuário e remover do system prompt.

B. Adicionar a regra de que erros de formatação serão penalizados e a resposta será rejeitada.

C. Escrever a mesma proibição três vezes e em letras maiúsculas para reforçar a prioridade.

D. Explicar o motivo: a resposta vai por SMS e o markdown aparece literalmente para o usuário.

Questão 50 · **Selecione 3 respostas.**

Um agente que resume páginas web e e-mails de remetentes desconhecidos vai para produção. Quais três práticas são coerentes com a defesa contra injeção indireta? Selecione 3.

A. Testar antes do deploy com documentos, e-mails e saídas de tools que contenham tentativas de injeção deliberadas.

B. Inserir o texto das páginas no system prompt para que Claude dê mais peso ao conteúdo recuperado.

C. Dar ao agente apenas as tools e os dados necessários, rodando-as em ambiente isolado com permissões restritas.

D. Dispensar testes adversariais, já que Claude é inerentemente resiliente a esse tipo de ataque.

E. Analisar continuamente as saídas em busca de sinais de injeção bem-sucedida e usar isso para refinar prompts e filtros.

Questão 51 · **Selecione 1 resposta.**

Você quer testar um plugin (com skills e hooks) apenas neste repositório, sem afetar seus outros projetos nem os colegas que usam o mesmo repo. Qual escopo de instalação escolher?

A. User scope, que o habilita para você em todos os projetos desta máquina.

B. Escopo gerenciado, definido pela organização para todos os desenvolvedores.

C. Project scope, registrando-o no .claude/settings.json versionado e pedindo aos colegas que o ignorem.

D. Local scope, que o habilita só para você neste repositório.

Questão 52 · **Selecione 1 resposta.**

Um pipeline de três chamadas ao Claude extrai campos de uma fatura, concilia com o ERP e redige um e-mail de cobrança. Às vezes a extração devolve campos obrigatórios vazios e o e-mail final sai confiante, porém com dados errados. Qual a melhor abordagem?

A. Acrescentar ao prompt do e-mail a instrução "tenha cuidado se os dados estiverem incompletos" e manter o restante do fluxo.

B. Fundir as três etapas em um único prompt maior, para que o modelo enxergue a tarefa inteira de uma vez.

C. Inserir, após a extração, uma verificação programática (gate) que valida os campos obrigatórios e interrompe ou repete a etapa antes de seguir.

D. Trocar o pipeline por um agente autônomo que decide sozinho quais etapas executar e em que ordem.

Questão 53 · **Selecione 1 resposta.**

Um agente construído com o Claude Agent SDK expõe uma ferramenta customizada get_order por meio de um servidor MCP em processo, registrado em mcpServers com a chave "shop". Claude enxerga e usa a ferramenta, mas, na execução sem interação humana, cada chamada fica parada esperando aprovação de permissão. Qual ajuste faz as chamadas rodarem sem prompt?

A. Marcar a ferramenta com readOnlyHint: true nas annotations, pois ferramentas somente leitura dispensam aprovação.

B. Reescrever a descrição da ferramenta para dizer que é segura, de modo que Claude não peça aprovação.

C. Passar tools: ["get_order"] nas opções, para a ferramenta ficar disponível e aprovada.

D. Incluir o nome totalmente qualificado mcp__shop__get_order (ou o curinga mcp__shop__*) em allowedTools.

Folha de respostas

1	(A)	(B)	(C)	(D)	(E)
2	(A)	(B)	(C)	(D)	(E)
3	(A)	(B)	(C)	(D)	(E)
4	(A)	(B)	(C)	(D)	(E)
5	(A)	(B)	(C)	(D)	(E)
6	(A)	(B)	(C)	(D)	(E)
7	(A)	(B)	(C)	(D)	(E)
8	(A)	(B)	(C)	(D)	(E)
9	(A)	(B)	(C)	(D)	(E)
10	(A)	(B)	(C)	(D)	(E)
11	(A)	(B)	(C)	(D)	(E)
12	(A)	(B)	(C)	(D)	(E)
13	(A)	(B)	(C)	(D)	(E)
14	(A)	(B)	(C)	(D)	(E)
15	(A)	(B)	(C)	(D)	(E)
16	(A)	(B)	(C)	(D)	(E)
17	(A)	(B)	(C)	(D)	(E)
18	(A)	(B)	(C)	(D)	(E)
19	(A)	(B)	(C)	(D)	(E)
20	(A)	(B)	(C)	(D)	(E)
21	(A)	(B)	(C)	(D)	(E)
22	(A)	(B)	(C)	(D)	(E)
23	(A)	(B)	(C)	(D)	(E)
24	(A)	(B)	(C)	(D)	(E)
25	(A)	(B)	(C)	(D)	(E)
26	(A)	(B)	(C)	(D)	(E)
27	(A)	(B)	(C)	(D)	(E)

28	(A)	(B)	(C)	(D)	(E)
29	(A)	(B)	(C)	(D)	(E)
30	(A)	(B)	(C)	(D)	(E)
31	(A)	(B)	(C)	(D)	(E)
32	(A)	(B)	(C)	(D)	(E)
33	(A)	(B)	(C)	(D)	(E)
34	(A)	(B)	(C)	(D)	(E)
35	(A)	(B)	(C)	(D)	(E)
36	(A)	(B)	(C)	(D)	(E)
37	(A)	(B)	(C)	(D)	(E)
38	(A)	(B)	(C)	(D)	(E)
39	(A)	(B)	(C)	(D)	(E)
40	(A)	(B)	(C)	(D)	(E)
41	(A)	(B)	(C)	(D)	(E)
42	(A)	(B)	(C)	(D)	(E)
43	(A)	(B)	(C)	(D)	(E)
44	(A)	(B)	(C)	(D)	(E)
45	(A)	(B)	(C)	(D)	(E)
46	(A)	(B)	(C)	(D)	(E)
47	(A)	(B)	(C)	(D)	(E)
48	(A)	(B)	(C)	(D)	(E)
49	(A)	(B)	(C)	(D)	(E)
50	(A)	(B)	(C)	(D)	(E)
51	(A)	(B)	(C)	(D)	(E)
52	(A)	(B)	(C)	(D)	(E)
53	(A)	(B)	(C)	(D)	(E)