Claude Certified Developer – Foundations (CCDV-F)

Dia 1 · Simulado 3

53 questões · Tempo: 120 minutos · Português

Instruções

- Cada questão informa quantas respostas selecionar. Nas de múltipla resposta, acerta-se somente com o conjunto exato de alternativas corretas (sem nota parcial).
- Meça o tempo: 120 minutos para 53 questões (cerca de 2 min 15 s por questão). Marque as dúvidas e volte a elas.
- Use somente a folha de respostas na última página. Não consulte materiais durante o simulado.
- Este é um material de estudo não oficial, com questões originais. Não reproduz itens reais do exame (confidenciais por NDA).

Domínio: D1 Agents & Workflows (8) · D2 Applications & Integration (17) · D3 Claude Code (2) · D4 Eval, Testing & Debugging (1) · D5 Model Selection & Optimization (9) · D6 Prompt & Context Engineering (6) · D7 Security & Safety (4) · D8 Tools & MCPs (6)

Questão 1 · **Selecione 3 respostas.**

O CI de uma equipe chama a API real do Claude em todo pull request: o pipeline é lento, caro e instável. A equipe quer testar o código de integração de forma confiável. Selecione 3 práticas adequadas.

A. Usar, no pipeline do PR, dublês do cliente da API com respostas realistas gravadas, incluindo tool_use, erros 429/529 e eventos de erro no stream

B. Medir a qualidade das respostas do modelo em uma suíte de evals separada, pois dublês só verificam o código de integração e não o comportamento do modelo

C. Rodar periodicamente uma pequena suíte de contrato contra a API real para checar se os dublês ainda refletem o formato real, abrindo tarefa de ajuste se divergirem

D. Escrever dublês apenas com o caminho feliz em JSON feito à mão, já que nunca será necessário comparar com respostas reais

E. Manter as chamadas reais em todo PR e repetir o job até ficar verde, pois a instabilidade é só ruído

Questão 2 · **Selecione 2 respostas.**

Sua tool update_ticket tem o parâmetro status como string livre. Em produção Claude envia "Done", "finished" e "fechado", mas a API só aceita open, in_progress e closed. Quais mudanças na definição da tool atacam a causa? Selecione 2.

A. Declarar status com "enum": ["open", "in_progress", "closed"] no input_schema e explicar cada valor na description do parâmetro.

B. Adicionar input_examples com chamadas válidas, mostrando os valores de status aceitos.

C. Usar tool_choice forçado do tipo tool, para que Claude sempre chame update_ticket.

D. Reduzir a description da tool a uma frase curta, para não confundir o modelo.

E. Mapear em silêncio, no handler, qualquer valor desconhecido para "open", para nunca falhar.

Questão 3 · **Selecione 1 resposta.**

Um dev ativa o thinking com display "omitted" para a resposta não trazer texto de raciocínio, achando que assim deixará de pagar pelo thinking. O que de fato acontece na cobrança?

A. O raciocínio é cobrado como tokens de input, a uma taxa menor que a de output.

B. Só o texto visível é cobrado; como o campo thinking vem vazio, os tokens de raciocínio ficam sem custo.

C. Os tokens de thinking realmente gerados são cobrados como output, independentemente do display; o detalhamento aparece em usage.output_tokens_details.thinking_tokens.

D. É cobrado apenas um resumo do raciocínio, proporcional ao tamanho do texto resumido.

Questão 4 · **Selecione 1 resposta.**

Um agente do Agent SDK tem três ferramentas customizadas, todas apenas de consulta (lookup_customer, lookup_order, lookup_inventory). Quando Claude pede as três no mesmo turno, elas rodam uma após a outra e a latência triplica. Qual a melhor correção?

A. Adicionar as três ferramentas a allowed_tools, para que o SDK as trate como seguras para execução concorrente.

B. Marcar as ferramentas com readOnlyHint nas annotations; customizadas são sequenciais por padrão.

C. Reduzir effort para low, para que Claude peça menos chamadas por turno e conclua o conjunto mais rápido.

D. Aumentar max_turns, para que Claude possa distribuir as chamadas por vários turnos e peça menos delas de cada vez.

Questão 5 · **Selecione 2 respostas.**

No meio de uma conversa longa no Claude Code, o desenvolvedor quer testar uma abordagem alternativa de refatoração partindo do histórico atual, sem alterar a conversa original, que deve continuar disponível. Selecione 2 formas adequadas.

A. /branch, com um nome opcional para a nova conversa.

B. claude --continue --fork-session, que copia o histórico para um novo ID de sessão.

C. /compact, que resume o histórico para liberar espaço.

D. /clear, que começa com o contexto vazio e preserva o histórico anterior.

E. claude --resume <nome>, que reabre a sessão e segue a partir dela.

Questão 6 · **Selecione 1 resposta.**

Um serviço captura Exception genérica ao chamar a API e decide o que fazer com checagens como `"overloaded" in str(e)`. Após uma mudança de redação nas mensagens de erro, o tratamento parou de funcionar. Qual é a melhor abordagem?

A. Capturar as classes de exceção tipadas do SDK, das mais específicas para as mais gerais, e decidir por tipo/status do erro.

B. Definir max_retries=0 no cliente, para que o SDK devolva o erro como JSON bruto em vez de lançar exceção.

C. Extrair o código HTTP com regex a partir do texto da mensagem de erro.

D. Adicionar mais substrings à checagem para cobrir as novas redações.

Questão 7 · **Selecione 2 respostas.**

Você extrai dados de contratos com a API usando saída estruturada. Muitos contratos não informam a data de término nem o foro, e o modelo às vezes inventa valores plausíveis para esses campos. Quais mudanças de schema reduzem o problema? Selecione 2.

A. Colocar todos os campos em required, para que o modelo sempre devolva um valor para cada um.

B. Adicionar minLength: 1 a todas as strings para impedir valores vazios.

C. Modelar o campo tipo_rescisao como enum que inclua um valor explícito como "nao_informado", em vez de string livre.

D. Deixar data_termino e foro fora de required, tornando-os opcionais, para que a ausência da informação possa ser representada.

E. Confiar que a saída estruturada garante que os valores extraídos sejam verdadeiros em relação ao documento.

Questão 8 · **Selecione 1 resposta.**

Você criou a skill /deploy, que executa o procedimento de deploy em produção. Quer que ela rode apenas quando você digitar /deploy, nunca por iniciativa de Claude por achar que a conversa pede um deploy. O que fazer?

A. Definir disable-model-invocation: true no frontmatter da skill.

B. Listar apenas ferramentas seguras em allowed-tools na skill.

C. Definir context: fork no frontmatter, para rodar em um subagent isolado.

D. Mover o procedimento para o CLAUDE.md, que só é lido quando você pede.

Questão 9 · **Selecione 2 respostas.**

Um agente do Agent SDK foi configurado com max_turns=5 para corrigir testes. Em produção, algumas execuções terminam sem nenhum texto final. Selecione 2 afirmações corretas sobre esse comportamento e seu tratamento.

A. O SDK dobra automaticamente max_turns e continua o loop quando o limite é atingido.

B. O ResultMessage ainda traz session_id, permitindo retomar a sessão com um limite maior para continuar o trabalho.

C. A execução termina com um ResultMessage de subtype error_max_turns, sem o campo result; o código deve checar o subtype antes de ler result.

D. Aumentar max_budget_usd também eleva o limite de turnos, então basta subir o orçamento para o loop rodar por mais tempo.

E. max_turns conta apenas turnos com chamadas de ferramenta; a resposta final só de texto nunca consome turno.

Questão 10 · **Selecione 1 resposta.**

Um banco vai lançar um chatbot de suporte baseado em Claude. A área de compliance exige que "toda resposta dada a um cliente seja auditável". Qual decisão de projeto atende melhor a esse requisito?

A. Persistir por resposta: id da conversa, versão do prompt, modelo, request-id da API e mensagens, com retenção definida

B. Registrar apenas o texto final exibido ao cliente, para reduzir o volume armazenado e o risco de reter dados sensíveis do banco

C. Ativar streaming, pois os eventos SSE recebidos pelo navegador do cliente já constituem um registro auditável da interação com o banco

D. Confiar nos logs mantidos pela Anthropic e solicitá-los ao provedor sempre que ocorrer uma auditoria interna, externa ou regulatória

Questão 11 · **Selecione 2 respostas.**

A equipe quer um procedimento /release que só rode quando alguém digitar o comando (nunca por decisão do Claude) e cujo material de referência longo (checklist e templates) não ocupe contexto em toda sessão. Selecione 2 práticas adequadas.

A. Colar o procedimento completo e os templates no CLAUDE.md do projeto, para o Claude consultá-los.

B. Definir user-invocable: false, para que a skill só seja usada de forma deliberada pela equipe.

C. Usar allowed-tools no frontmatter para controlar quando o Claude pode acionar a skill.

D. Criar .claude/skills/release/SKILL.md com disable-model-invocation: true.

E. Manter checklist e templates em arquivos separados na pasta da skill, citados no SKILL.md.

Questão 12 · **Selecione 3 respostas.**

Um job noturno envia 50 mil requisições ao Message Batches API, todas com o mesmo documento de 30k tokens como prefixo e perguntas diferentes. Não há urgência de resposta. Selecione 3 práticas corretas para minimizar o custo.

A. Dentro do lote, fazer uma requisição com max_tokens 0 para pré-aquecer o cache antes das demais requisições.

B. Incluir blocos cache_control idênticos em todas as requisições do lote para aumentar a chance de hits.

C. Contar com hits garantidos, já que o lote processa as requisições em ordem sequencial rigorosa e previsível.

D. Considerar o TTL de 1 hora, pois lotes podem levar mais de 5 minutos para processar.

E. Usar o Batches API, que dá 50% de desconto para trabalho assíncrono sem urgência.

Questão 13 · **Selecione 2 respostas.**

Seu time habilitou 12 plugins no Claude Code e nota que as sessões começam com menos espaço de contexto, mesmo em tarefas que usam poucos deles. Quais afirmações sobre o custo dos plugins são verdadeiras? Selecione 2.

A. Dá para parar o custo sem desinstalar, desabilitando o plugin com /plugin ou com claude plugin disable.

B. O nome e a descrição de cada skill que Claude pode invocar sozinho ficam no contexto a cada turno, mesmo em sessões em que nada do plugin é usado.

C. Desinstalar é a única forma de remover o custo de contexto de um plugin.

D. Um plugin só afeta a sessão quando uma de suas skills é invocada; hooks e servidores MCP ficam inativos até lá.

E. O texto completo de todas as skills dos plugins habilitados é carregado no início de cada sessão.

Questão 14 · **Selecione 3 respostas.**

Um dev está estimando quanto da janela de contexto uma requisição de agente consome. A requisição tem system prompt, 12 definições de tools, histórico com blocos tool_result e o texto que Claude vai gerar no turno. Quais afirmações sobre o que conta para a janela de contexto são corretas? Selecione 3.

A. O conteúdo dos blocos tool_result no histórico conta como qualquer outra mensagem.

B. O texto que Claude gera no turno, incluindo o thinking, conta para a janela.

C. As definições de tools contam para a janela, assim como o system prompt.

D. Tokens lidos de um prefixo em cache (prompt caching) deixam de ocupar a janela; o cache altera apenas o preço.

E. Só as mensagens user/assistant contam; system prompt e definições de tools ficam fora da conta.

Questão 15 · **Selecione 2 respostas.**

Um time quer reduzir o risco de vazar chaves de API da Claude antes que aconteça qualquer incidente. Quais duas práticas de prevenção são recomendadas? Selecione 2.

A. Manter a mesma chave sem rotação até suspeitar de vazamento.

B. Verificar regularmente os repositórios com uma ferramenta como Gitleaks.

C. Codificar a chave em base64 no bundle do front-end para que não fique legível.

D. Compartilhar uma única chave do time por chat para acelerar o onboarding.

E. Carregar a chave por variável de ambiente e listar .env no .gitignore.

Questão 16 · **Selecione 1 resposta.**

Um prompt cola três contratos como texto corrido separados por linhas '---', seguidos das instruções. Claude às vezes atribui uma cláusula ao contrato errado e confunde trechos dos contratos com as instruções. Qual a melhor correção?

A. Mover os três contratos para o system prompt, para que tenham mais autoridade que as instruções em toda requisição.

B. Envolver cada contrato em <document index="n"> com <source> e <document_content>, dentro de <documents>.

C. Repetir as instruções depois de cada um dos contratos para que Claude não as confunda com o texto dos contratos.

D. Trocar os separadores '---' por banners em letras maiúsculas como '=== CONTRATO 2 ==='.

Questão 17 · **Selecione 1 resposta.**

Um agente de suporte lê tickets de clientes e tem a tool query_db com credencial de administrador do banco e a tool send_email sem restrição de destinatário. A equipe teme que um ticket malicioso faça o agente exfiltrar dados. Qual a melhor abordagem?

A. Pedir educadamente nos tickets de teste que o agente ignore instruções contidas no texto do cliente.

B. Adicionar ao system prompt a frase 'nunca envie dados a terceiros' e manter as permissões atuais.

C. Credencial somente leitura nas tabelas necessárias, tools estreitas e nenhum segredo desnecessário.

D. Registrar logs de auditoria de todas as chamadas de tool e revisá-los semanalmente, mantendo as permissões.

Questão 18 · **Selecione 2 respostas.**

Sua equipe tem a função lookup_customer, que consulta o CRM. Hoje só um serviço interno, que chama a Messages API, a usa. Em breve ela também será usada no Claude Code, no Claude Desktop e em outro app. Quais motivos justificam empacotá-la como servidor MCP? Selecione 2.

A. Vários hosts (Claude Code, Claude Desktop, outros apps) usam o mesmo servidor, sem reimplementar a tool.

B. Tools definidas no código da aplicação não conseguem acessar APIs internas, como o CRM da empresa; só servidores MCP conseguem.

C. A Messages API só aceita tools que venham de servidores MCP, não funções definidas pelo seu código.

D. A conexão e a autenticação com o CRM ficam em um só lugar, no servidor, e não duplicadas em cada cliente.

E. Uma tool exposta por MCP é chamada pelo modelo com mais precisão do que uma tool definida no código da própria aplicação.

Questão 19 · **Selecione 2 respostas.**

Um assistente responde perguntas sobre um relatório anual e, às vezes, afirma com tom confiante números que não estão no relatório. Quais duas medidas ajudam a reduzir e detectar isso? Selecione 2.

A. Rodar o prompt várias vezes e revisar as respostas divergentes, que podem indicar alucinação.

B. Instruir Claude a completar com conhecimento geral quando o relatório não trouxer o dado, para manter a utilidade.

C. Dispensar a validação humana depois de restringir as respostas ao relatório, pois o risco deixa de existir.

D. Pedir que Claude informe uma confiança de 0 a 100 e aceitar automaticamente respostas acima de 90, sem revisão.

E. Permitir que Claude responda que não há informação suficiente quando o relatório não trouxer o dado.

Questão 20 · **Selecione 2 respostas.**

O requisito de um chatbot de suporte diz apenas: "deve ser rápido e estar sempre disponível". Antes de projetar, a equipe precisa transformá-lo em requisitos verificáveis. Selecione 2 abordagens adequadas.

A. Fixar 100% de disponibilidade como meta, sem nenhuma resposta de erro tolerada em qualquer período, e provisionar capacidade para isso

B. Definir p95 de tempo até o primeiro token abaixo de um valor acordado, sob carga especificada, medido em produção

C. Exigir latência média abaixo do alvo, já que a média resume bem a experiência de todos os usuários e é simples de acompanhar

D. Definir um SLO de disponibilidade (% de requisições com sucesso no mês) e o comportamento degradado em 429 ou 529

E. Escolher sempre o maior modelo disponível, pois a capacidade extra garante respostas rápidas e disponibilidade em horários de pico

Questão 21 · **Selecione 1 resposta.**

O repositório tem .claude/settings.json versionado com permissions.allow ["Bash(npm run lint)"] e permissions.deny ["Read(./.env)"]. Uma pessoa nova clona o repo e abre o Claude Code, ainda sem ter confiado (trust) na pasta. O que acontece?

A. Nenhuma das duas vale até a confiança, então o .env pode ser lido nesse intervalo.

B. A regra allow vale de imediato, enquanto a deny só vale após confiar na pasta, por exigir confirmação.

C. A regra deny vale de imediato; a regra allow só passa a valer depois de confiar na pasta, então o lint ainda pede confirmação.

D. As duas regras valem imediatamente, pois o arquivo está versionado no repositório.

Questão 22 · **Selecione 1 resposta.**

Sua empresa quer um servidor MCP somente-leitura sobre o ERP, usado por centenas de devs no Claude Code (e por outros apps), com identificação do usuário em cada acesso. Qual desenho é o mais adequado?

A. Servidor remoto com transporte SSE, por ser o mais recomendado para serviços remotos que mantêm conexões longas.

B. Um único processo stdio em um host central, ao qual todos os devs se conectam ao mesmo tempo, com a credencial do ERP configurada nele.

C. Servidor remoto Streamable HTTP com autenticação HTTP padrão (OAuth) e clientes conectando por URL.

D. Servidor stdio que cada dev executa localmente, com a credencial do ERP em variável de ambiente da própria máquina.

Questão 23 · **Selecione 1 resposta.**

Uma ferramenta interna chama o Claude uma vez a cada ~30 minutos com o mesmo prefixo grande e cache_control com o TTL padrão. A cobrança subiu após habilitar caching e a resposta mostra cache_creation_input_tokens alto e cache_read_input_tokens sempre 0. Qual é a melhor interpretação e ação?

A. O prefixo é pequeno demais, por isso nada é lido; aumentar max_tokens resolve.

B. O TTL padrão (5 minutos) expira antes da próxima chamada (~30 minutos): toda requisição paga a escrita no cache e nunca lê; a ação é remover o caching ou avaliar o TTL de 1 hora, que cobre esse intervalo entre chamadas.

C. Os campos de usage estão errados em modelos recentes; o cache está funcionando e a cobrança vai estabilizar.

D. É preciso adicionar mais breakpoints (até 4) para que o cache comece a ser lido.

Questão 24 · **Selecione 1 resposta.**

Uma equipe guarda o system prompt de um extrator em um repositório e o edita no lugar sob o rótulo "v2". Uma reformulação "pequena" mudou o formato da saída, quebrou o parser downstream e foi para 100% do tráfego de uma vez, mesmo com os evals offline passando. A equipe decide adotar versionamento semântico (SemVer) para os prompts. Qual abordagem de versionamento e rollout é a melhor?

A. Escolher o número da versão pelo tamanho do diff: poucas linhas alteradas significam PATCH, mesmo que o formato da saída mude, e reservar MAJOR para reescritas extensas do prompt

B. Liberar direto para 100% quando os evals offline passarem, pois eles substituem a observação em produção

C. Manter o rótulo "v2" e sobrescrevê-lo a cada ajuste, pois o histórico do Git já permite voltar a qualquer versão anterior

D. Declarar o formato de saída como API pública do prompt, versões publicadas imutáveis (formato quebrado = MAJOR), evals como portão e canário com rollback

Questão 25 · **Selecione 2 respostas.**

Um subagente de revisão foi definido em .claude/agents/reviewer.md, com description "Revisor somente leitura; nunca altera arquivos" e sem campo tools. Mesmo assim ele usou Write e Edit. A equipe exige que essas duas ferramentas fiquem indisponíveis para ele. Selecione 2 ajustes eficazes.

A. Adicionar disallowedTools: Write, Edit ao frontmatter do subagente.

B. Definir isolation: worktree, para que as edições nunca cheguem ao checkout principal.

C. Reforçar no campo description que o subagente jamais deve usar Write ou Edit.

D. Adicionar tools: Read, Grep, Glob ao frontmatter do subagente.

E. Definir model: haiku, pois um modelo menor tende a editar menos.

Questão 26 · **Selecione 1 resposta.**

Um app de FAQ em um modelo tier Sonnet usa adaptive thinking. Monitorando, você vê blocos de thinking em muitas perguntas triviais, aumentando latência e custo de output. Adicionar ao system prompt "não pense, responda direto" não reduziu de forma confiável. Qual é a melhor abordagem?

A. Definir um budget_tokens pequeno em thinking, para limitar o raciocínio a poucos tokens.

B. Reduzir o nível de effort (output_config.effort), medir o impacto na qualidade e só então complementar com orientação no prompt, se necessário.

C. Reforçar o system prompt com mais ênfase ("NUNCA pense") e assumir que o modelo obedecerá sempre.

D. Aumentar max_tokens para que o thinking termine mais rápido e libere a resposta.

Questão 27 · **Selecione 1 resposta.**

Um time cria um hook PreToolUse que detecta quando Claude Code tenta ler um arquivo .env, imprime uma mensagem no stderr e termina com exit 1. Mesmo assim, o arquivo continua sendo lido. Qual a melhor correção?

A. Manter exit 1, que por ser o código convencional de falha em Unix já bloqueia a ação.

B. Mover a lógica para um hook PostToolUse, que roda depois que a tool executou e recebe seu resultado.

C. Usar exit 2: em PreToolUse bloqueia a chamada e o stderr vira a mensagem.

D. Imprimir a mensagem no stdout e terminar com exit 0, pois a mensagem sozinha cancela a tool call.

Questão 28 · **Selecione 2 respostas.**

A tool get_invoice(invoice_id) roda no seu backend, com strict: true e invoice_id como string no schema. Outra tool devolve, em um tool_result, o texto de um e-mail de terceiros que tenta induzir Claude a pedir a fatura de OUTRO cliente. Quais afirmações são verdadeiras? Selecione 2.

A. strict: true garante que o invoice_id enviado pertença ao cliente autenticado, validando a propriedade da fatura.

B. strict: true garante que as entradas da tool correspondam ao schema declarado.

C. O conteúdo não confiável deve ser colocado no system prompt, que é o lugar mais seguro para ele, com prioridade maior.

D. Conteúdo externo em tool_result, como e-mails, deve ser tratado como não confiável, pois pode embutir instruções (injeção indireta de prompt).

E. O e-mail está dentro de um tool_result, então o seu conteúdo é confiável por vir do seu próprio backend, que o entregou.

Questão 29 · **Selecione 1 resposta.**

Trace de um agente: nos turnos 1, 2 e 3 Claude chama search_docs com {"query":"rate limits"} e recebe is_error=true: "Missing required 'repo' parameter". No turno 4 ele pede desculpas e desiste. O schema de search_docs exige repo, mas a descrição é "Search docs." e repo não tem description. Qual a melhor correção?

A. Aumentar max_turns para que Claude acabe acertando o parâmetro em mais tentativas.

B. Aumentar tentativas e backoff no executor da ferramenta, pois a integração está falhando.

C. Trocar para tool_choice forçado em search_docs, pois Claude escolheu a ferramenta errada.

D. Detalhar a descrição da ferramenta e do parâmetro repo (o que é, valores válidos) e habilitar strict: true, tratando o problema como definição insuficiente.

Questão 30 · **Selecione 1 resposta.**

Seu app usa a Messages API com uma tool client issue_refund, que movimenta dinheiro. Você quer que um humano aprove cada reembolso antes de ele acontecer. Qual abordagem?

A. Transformar issue_refund em server tool, para que a execução e a aprovação fiquem a cargo da Anthropic, sem código próprio para essa etapa.

B. No código que trata tool_use, pausar antes de executar, pedir aprovação e, se negada, devolver tool_result com is_error true.

C. Deixar o handler executar o reembolso e, se o humano discordar depois, pedir a Claude que estorne.

D. Escrever na description da tool "sempre peça aprovação ao usuário antes de chamar" e confiar que Claude cumprirá em cada conversa com clientes.

Questão 31 · **Selecione 1 resposta.**

Um app faz streaming de uma resposta em que Claude chama uma ferramenta. O código executa json.loads em cada partial_json recebido nos eventos input_json_delta e lança exceção em quase todo evento. Qual a abordagem correta?

A. Capturar a exceção e usar o último fragmento que foi parseado com sucesso como os argumentos da ferramenta

B. Acumular os fragmentos por índice de bloco, fazer o parse ao receber content_block_stop e só então executar a ferramenta

C. Executar a ferramenta assim que o primeiro campo aparecer no fragmento, com um regex, para reduzir a latência

D. Desativar o streaming apenas durante o tool use, pois não há forma de obter o JSON dos argumentos em requisições com stream

Questão 32 · **Selecione 1 resposta.**

Uma equipe usa uma única chamada ao Claude para revisar mudanças de código em busca de vulnerabilidades. O problema é a variância: em execuções repetidas, achados reais ora aparecem, ora somem. Que padrão de workflow ataca esse problema?

A. Voting: rodar a mesma revisão várias vezes de forma independente e sinalizar a mudança quando um número suficiente de execuções apontar problema.

B. Routing: classificar cada mudança por linguagem e encaminhá-la a um prompt de revisão especializado.

C. Prompt chaining: encadear a revisão por um segundo prompt que reescreve e refina o texto do relatório.

D. Sectioning: dividir o diff em partes independentes e processar cada parte em paralelo, cada uma com um prompt diferente.

Questão 33 · **Selecione 2 respostas.**

Uma aplicação usa um modelo com janela de 1M tokens. Cada requisição envia um prefixo de 300k tokens marcado com prompt caching, mais a pergunta do usuário, com adaptive thinking ativo e max_tokens definido. Um colega faz afirmações sobre o uso da janela de contexto. Selecione 2 afirmações corretas.

A. Os tokens de thinking gerados contam para a janela de contexto e fazem parte do limite de max_tokens.

B. A janela limita apenas o input; os tokens de saída são contabilizados em um limite separado de geração.

C. Os 300k tokens do prefixo lidos do cache continuam ocupando a janela; o caching muda o preço, não o espaço.

D. Tokens lidos do cache não contam para a janela, pois não são reprocessados como input normal pelo modelo.

E. Se o input sozinho exceder a janela, a API trunca silenciosamente as mensagens mais antigas e responde normalmente.

Questão 34 · **Selecione 2 respostas.**

Antes de enviar prompts grandes, sua API interna chama o endpoint de contagem de tokens para decidir roteamento e checar limites. Selecione 2 afirmações corretas sobre esse endpoint.

A. Retorna uma estimativa; o número real de tokens de input na criação pode diferir um pouco.

B. Retorna o número exato que será faturado, sempre idêntico ao usage da resposta real do modelo.

C. É gratuito, com limite de requisições por minuto próprio, separado do da criação de mensagens.

D. Respeita blocos cache_control, então o resultado já reflete o desconto de leitura de cache na fatura.

E. Aceita a mesma requisição da Messages API, inclusive com server tools como web search e code execution.

Questão 35 · **Selecione 1 resposta.**

Um agente do Agent SDK recebeu no prompt inicial a regra "escreva sempre as notas de release em português". Em sessões longas, após eventos compact_boundary, ele passa a escrever em inglês. Qual a melhor correção?

A. Definir effort como max para que o modelo lembre melhor das instruções iniciais ao longo da sessão.

B. Colocar a regra em CLAUDE.md carregado via setting_sources, reinjetado em cada requisição.

C. Aumentar max_budget_usd para que o contexto original não seja resumido pela compactação automática.

D. Retomar a sessão a cada turno com o session_id para restaurar o prompt original antes de responder.

Questão 36 · **Selecione 1 resposta.**

Em um loop de agente, uma resposta chega com stop_reason "max_tokens" e o último bloco de conteúdo é um tool_use cujo input JSON parece cortado no meio. O que fazer?

A. Tratar a resposta como incompleta e repetir a requisição com um max_tokens maior, em vez de executar a ferramenta.

B. Enviar o tool_use parcial de volta como tool_result e pedir ao modelo que complete o JSON.

C. Executar a ferramenta com o input parcial, assumindo que os campos que chegaram bastam.

D. Ignorar o stop_reason, pois o SDK completa automaticamente chamadas de ferramenta truncadas.

Questão 37 · **Selecione 3 respostas.**

Um serviço Node processa 2.000 documentos disparando todas as chamadas à API com Promise.all e recebe uma enxurrada de erros 429. Selecione 3 correções adequadas.

A. Aumentar a carga de forma gradual em vez de saltar do zero ao pico, evitando também os limites de aceleração

B. Repetir a requisição imediatamente em loop, até uma das tentativas passar

C. Adicionar retries independentes em cada camada (fila, serviço e cliente), para que cada falha tenha mais chances de passar

D. Limitar a concorrência com um pool de workers ou semáforo, dimensionado abaixo dos limites de taxa da organização

E. Aplicar retry com backoff exponencial e jitter, respeitando o header retry-after quando presente e com número máximo de tentativas

Questão 38 · **Selecione 1 resposta.**

Um agente do Agent SDK vai conduzir uma refatoração extensa. A equipe quer que ele leia o código e proponha um plano para aprovação humana antes de modificar qualquer arquivo. Qual permission_mode atende?

A. plan: Claude explora e planeja, e as edições vão para o callback canUseTool.

B. dontAsk, que nunca pergunta e por isso nada não revisado chega a ser executado; o que não estiver pré-aprovado é negado.

C. bypassPermissions, que executa as chamadas sem pedir aprovação e é recomendado para testes locais.

D. acceptEdits, que aprova edições automaticamente para acelerar a iteração, mantendo o pedido de confirmação para outros comandos.

Questão 39 · **Selecione 1 resposta.**

No Claude Code do seu time há duas instruções: (1) "os testes rodam com pnpm test e os handlers da API ficam em src/api/handlers/"; (2) "respostas curtas, com pouca explicação", que alguns devs querem desligar quando estão aprendendo o código. Onde colocar cada uma?

A. (1) em uma skill com disable-model-invocation; (2) em um hook SessionStart.

B. (1) em CLAUDE.md; (2) em um output style, que pode ser trocado quando se quiser.

C. (1) em um output style; (2) em CLAUDE.md.

D. As duas em CLAUDE.md, pois ele é carregado em toda sessão e cobre qualquer tipo de instrução.

Questão 40 · **Selecione 1 resposta.**

Uma equipe vai migrar de um modelo de geração antiga para um tier de geração mais nova, mantendo os mesmos prompts. O orçamento de custo e a verificação de "cabe na janela" usam contagens de tokens medidas no modelo antigo. Qual é a melhor abordagem?

A. Reaproveitar as contagens, pois o número de tokens de um texto é o mesmo em qualquer modelo Claude, então não é preciso recontar nem refazer o custo.

B. Reavaliar só se o preço por milhão de tokens mudar; caso contrário, o orçamento continua válido.

C. Recontar os prompts com o endpoint de contagem usando o modelo de destino, refazer estimativas de custo e janela e rodar evals.

D. Assumir que modelos mais novos sempre geram menos tokens para o mesmo texto e reduzir o orçamento.

Questão 41 · **Selecione 1 resposta.**

Um serviço usa output_config.format com um JSON schema e grava a saída do Claude direto no banco. Em produção, às vezes o parse falha em respostas cortadas ao meio. Qual a melhor abordagem?

A. Aplicar uma função que "conserta" JSON truncado, fechando chaves e aspas, e gravar o resultado reparado

B. Tratar a saída como sempre válida, já que structured outputs garantem o schema em qualquer resposta

C. Remover o schema e iniciar o turno do assistente com "{" para forçar o formato JSON nos modelos mais recentes

D. Verificar o stop_reason antes de parsear, tratar max_tokens (retry com limite maior) e refusal como casos à parte, e validar na borda antes de gravar

Questão 42 · **Selecione 1 resposta.**

Em uma sessão longa do Claude Code você pede um ajuste de formatação. Claude erra, você corrige, e ele erra a mesma coisa de novo. Qual a melhor ação a seguir?

A. Rodar /clear e começar com um único prompt novo que já incorpora o que você aprendeu nas tentativas.

B. Fazer uma terceira correção, escrevendo a instrução em letras maiúsculas para dar ênfase.

C. Adicionar ao CLAUDE.md a frase em CAPS LOCK com IMPORTANT e continuar na mesma sessão.

D. Continuar corrigindo na mesma conversa, pois mais histórico de tentativas dá mais contexto ao modelo.

Questão 43 · **Selecione 3 respostas.**

Um job com a Message Batches API de 5.000 requisições terminou com 4.700 resultados succeeded, 200 errored e 100 expired. Selecione 3 práticas corretas para consolidar e recuperar o trabalho.

A. Reenviar em um novo batch os itens expired e com erro de servidor, e corrigir antes os itens com invalid_request_error

B. Associar cada resultado à entrada pela posição da linha no arquivo de resultados, já que ele segue a ordem de envio

C. Associar cada resultado à entrada de origem pelo custom_id, pois a ordem dos resultados não é garantida

D. Contar que itens errored e expired não são cobrados, então reprocessá-los não paga duas vezes pelo mesmo trabalho

E. Reenviar o batch inteiro de 5.000 itens para garantir que todos os resultados venham do mesmo processamento

Questão 44 · **Selecione 1 resposta.**

Em um chat com Claude, o dev chama a Messages API a cada turno enviando só a nova mensagem do usuário. O assistente "esquece" tudo o que foi dito antes. Qual a correção mais adequada?

A. Aumentar max_tokens, para que o modelo consiga reter mais contexto entre uma chamada e outra

B. Enviar a cada chamada apenas as falas anteriores do usuário, omitindo as respostas do assistente para economizar tokens

C. Reutilizar o mesmo header request-id em todos os turnos, para que a API associe as chamadas à mesma conversa

D. Guardar a lista de mensagens da conversa e enviá-la completa a cada chamada, anexando a resposta do assistente e a nova fala do usuário

Questão 45 · **Selecione 1 resposta.**

Um serviço de triagem usa output_config.format com um JSON schema cujo campo "categoria" é um enum com os valores "Cobrança", "Suporte técnico" e "Outros". O código compara a categoria recebida por igualdade exata e, de vez em quando, cai no ramo "desconhecido" porque chegou, por exemplo, "Suporte Técnico". Qual a melhor correção?

A. Comparar o valor sem diferenciar maiúsculas de minúsculas e evitar enum que difira só na capitalização.

B. Abandonar structured outputs e pedir JSON em texto livre, perdendo a conformidade de estrutura garantida pelo schema.

C. Assumir que o schema garante a grafia exata do enum e tratar a divergência como bug da API a ser reportado ao suporte.

D. Tratar como erro transitório e repetir a requisição até o valor vir exatamente como no schema, com limite de tentativas.

Questão 46 · **Selecione 1 resposta.**

Um pipeline gera resumos de contratos. O time quer registrar o rascunho, avaliar a revisão do rascunho contra critérios e, entre as etapas, decidir se segue para o refinamento ou desvia para revisão humana. Qual a melhor abordagem?

A. Dividir em chamadas sequenciais (rascunho, revisão, refinamento) e ramificar a partir da saída de cada etapa.

B. Um único prompt que pede rascunho, revisão e versão final, retornando só a versão final para reduzir tokens.

C. Aumentar o effort da chamada única para que a revisão interna fique mais rigorosa e dispensar o log das etapas.

D. Confiar no adaptive thinking para fazer as três etapas internamente, já que o modelo raciocina sobre múltiplos passos sozinho.

Questão 47 · **Selecione 1 resposta.**

Um chat web mostra a resposta do Claude token a token. O usuário envia cada pergunta por uma requisição POST normal, e o servidor só precisa empurrar texto de volta durante a geração. Qual transporte do servidor para o navegador é a melhor escolha?

A. Chamar a API da Anthropic direto do navegador com a chave embutida no JavaScript, eliminando o servidor intermediário

B. Polling a cada 100 ms em um endpoint, buscando os novos tokens acumulados

C. WebSocket, porque streaming de respostas exige um canal bidirecional entre navegador e servidor

D. Server-Sent Events sobre HTTP, pois o fluxo é apenas do servidor para o cliente e o navegador reconecta automaticamente

Questão 48 · **Selecione 1 resposta.**

Seu time quer que todos no repositório iniciem o Claude Code com o mesmo modelo por padrão, e que mudar essa escolha passe por code review e possa ser revertida. Qual abordagem?

A. Cada dev roda /model e salva a escolha, que é gravada no ~/.claude/settings.json de cada um.

B. Escrever no CLAUDE.md do projeto uma linha pedindo que Claude use o modelo desejado.

C. Definir a chave model em .claude/settings.json e versioná-la no repositório.

D. Definir a chave model no .claude/settings.local.json de cada dev.

Questão 49 · **Selecione 1 resposta.**

A saída de Claude é enviada a um gateway de SMS que quebra com markdown. O system prompt diz 'NUNCA use markdown' e ainda aparecem asteriscos de vez em quando. Qual a melhor melhoria?

A. Mover a proibição para o fim de cada mensagem do usuário e tirá-la do system prompt.

B. Adicionar a regra de que erros de formatação serão penalizados e a resposta será rejeitada pelo gateway.

C. Escrever a mesma proibição três vezes e em letras maiúsculas para reforçar a prioridade da regra no prompt.

D. Explicar o motivo: a resposta vai por SMS e o markdown aparece literalmente para o usuário.

Questão 50 · **Selecione 3 respostas.**

Um agente que resume páginas web e e-mails de remetentes desconhecidos vai para produção. Quais três práticas são coerentes com a defesa contra injeção indireta? Selecione 3.

A. Testar antes do deploy com documentos, e-mails e saídas de tools com tentativas de injeção deliberadas.

B. Inserir o texto das páginas no system prompt para que Claude dê mais peso ao conteúdo recuperado durante o resumo.

C. Dar ao agente apenas as tools e dados necessários, em ambiente isolado com permissões restritas.

D. Dispensar testes adversariais, já que Claude é inerentemente resiliente a esse tipo de ataque e não precisa de validação.

E. Analisar continuamente as saídas atrás de sinais de injeção bem-sucedida e refinar prompts e filtros.

Questão 51 · **Selecione 1 resposta.**

Você quer testar um plugin (com skills e hooks) apenas neste repositório, sem afetar seus outros projetos nem os colegas que usam o mesmo repo. Qual escopo de instalação escolher?

A. User scope, que o habilita para você em todos os projetos desta máquina.

B. Escopo gerenciado, definido pela organização para todos os desenvolvedores.

C. Project scope, registrando-o no .claude/settings.json versionado e pedindo aos colegas que o ignorem.

D. Local scope, que o habilita só para você neste repositório.

Questão 52 · **Selecione 1 resposta.**

Um pipeline de três chamadas ao Claude extrai campos de uma fatura, concilia com o ERP e redige um e-mail de cobrança. Às vezes a extração devolve campos obrigatórios vazios e o e-mail final sai confiante, porém com dados errados. Qual a melhor abordagem?

A. Acrescentar ao prompt do e-mail a instrução "tenha cuidado se os dados estiverem incompletos" e manter o restante do fluxo como está.

B. Fundir as três etapas em um único prompt maior, para que o modelo enxergue a tarefa inteira de uma vez.

C. Inserir um gate programático após a extração que valide os campos obrigatórios e barre ou repita a etapa.

D. Trocar o pipeline por um agente autônomo que decide sozinho, em tempo de execução, quais etapas executar e em que ordem.

Questão 53 · **Selecione 1 resposta.**

Um agente construído com o Claude Agent SDK expõe uma ferramenta customizada get_order por meio de um servidor MCP em processo, registrado em mcpServers com a chave "shop". Claude enxerga e usa a ferramenta, mas, na execução sem interação humana, cada chamada fica parada esperando aprovação de permissão. Qual ajuste faz as chamadas rodarem sem prompt?

A. Marcar a ferramenta com readOnlyHint: true nas annotations, pois ferramentas somente leitura dispensam aprovação.

B. Reescrever a descrição da ferramenta para dizer que é segura, de modo que Claude não peça aprovação.

C. Passar tools: ["get_order"] nas opções, para a ferramenta ficar disponível e aprovada.

D. Listar mcp__shop__get_order (ou o curinga mcp__shop__*) em allowedTools.

Folha de respostas

1	(A)	(B)	(C)	(D)	(E)
2	(A)	(B)	(C)	(D)	(E)
3	(A)	(B)	(C)	(D)	(E)
4	(A)	(B)	(C)	(D)	(E)
5	(A)	(B)	(C)	(D)	(E)
6	(A)	(B)	(C)	(D)	(E)
7	(A)	(B)	(C)	(D)	(E)
8	(A)	(B)	(C)	(D)	(E)
9	(A)	(B)	(C)	(D)	(E)
10	(A)	(B)	(C)	(D)	(E)
11	(A)	(B)	(C)	(D)	(E)
12	(A)	(B)	(C)	(D)	(E)
13	(A)	(B)	(C)	(D)	(E)
14	(A)	(B)	(C)	(D)	(E)
15	(A)	(B)	(C)	(D)	(E)
16	(A)	(B)	(C)	(D)	(E)
17	(A)	(B)	(C)	(D)	(E)
18	(A)	(B)	(C)	(D)	(E)
19	(A)	(B)	(C)	(D)	(E)
20	(A)	(B)	(C)	(D)	(E)
21	(A)	(B)	(C)	(D)	(E)
22	(A)	(B)	(C)	(D)	(E)
23	(A)	(B)	(C)	(D)	(E)
24	(A)	(B)	(C)	(D)	(E)
25	(A)	(B)	(C)	(D)	(E)
26	(A)	(B)	(C)	(D)	(E)
27	(A)	(B)	(C)	(D)	(E)

28	(A)	(B)	(C)	(D)	(E)
29	(A)	(B)	(C)	(D)	(E)
30	(A)	(B)	(C)	(D)	(E)
31	(A)	(B)	(C)	(D)	(E)
32	(A)	(B)	(C)	(D)	(E)
33	(A)	(B)	(C)	(D)	(E)
34	(A)	(B)	(C)	(D)	(E)
35	(A)	(B)	(C)	(D)	(E)
36	(A)	(B)	(C)	(D)	(E)
37	(A)	(B)	(C)	(D)	(E)
38	(A)	(B)	(C)	(D)	(E)
39	(A)	(B)	(C)	(D)	(E)
40	(A)	(B)	(C)	(D)	(E)
41	(A)	(B)	(C)	(D)	(E)
42	(A)	(B)	(C)	(D)	(E)
43	(A)	(B)	(C)	(D)	(E)
44	(A)	(B)	(C)	(D)	(E)
45	(A)	(B)	(C)	(D)	(E)
46	(A)	(B)	(C)	(D)	(E)
47	(A)	(B)	(C)	(D)	(E)
48	(A)	(B)	(C)	(D)	(E)
49	(A)	(B)	(C)	(D)	(E)
50	(A)	(B)	(C)	(D)	(E)
51	(A)	(B)	(C)	(D)	(E)
52	(A)	(B)	(C)	(D)	(E)
53	(A)	(B)	(C)	(D)	(E)